

Introducción GP

Rafael Molina

University of Granada (Spain)

<http://decsai.ugr.es/~rms>
rms@decsai.ugr.es

Índice

- La distribución de Gauss*
- De distribuciones gaussianas a procesos gaussianos
 - Funciones de covarianza
- Interpretación de un GP a través de un modelo generativo

* Recordatorio

I. La distribución de Gauss


Caso Unidimensional

$$Pr(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp[-0.5(x - \mu)^2/\sigma^2]$$

que también escribiremos:

Notación de Prince

$$Pr(x|\mu, \sigma^2) = \text{Norm}_x[\mu, \sigma^2] = \mathcal{N}(x|\mu, \sigma^2)$$



La distribución Normal Univariante describe una variable continua unidimensional.

Utiliza 2 parámetros μ y $\sigma^2 > 0$

I. La distribución de Gauss


Caso Multi-dimensional

D es el número de componentes de \mathbf{x}

$$Pr(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}} \exp[-0.5(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})]$$

que también escribimos

Notación de Prince


$$Pr(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \text{Norm}_{\mathbf{x}}[\boldsymbol{\mu}, \boldsymbol{\Sigma}] = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

La distribución Normal Multivariante describe variables aleatorias múltiples. Utiliza dos parámetros:

- Un vector que contiene las medias, $\boldsymbol{\mu}$
- Una matriz de covarianzas simétrica “definida positiva” $\boldsymbol{\Sigma}$

Matriz definida positiva: $\mathbf{z}^T \boldsymbol{\Sigma} \mathbf{z}$ es positivo para cualquier vector no nulo \mathbf{z}

Transformación de Variables (**muy importante**)


Si

$$Pr(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \text{Norm}_{\mathbf{x}}[\boldsymbol{\mu}, \boldsymbol{\Sigma}]$$

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$$

entonces

$$Pr(\mathbf{y}) = \text{Norm}_{\mathbf{y}}[\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T]$$



Transformación de Variables (**muy importante**)

Si

$$\mathbf{y} = \mathbf{A}\mathbf{x} + \boldsymbol{\epsilon}$$

donde

$$\begin{aligned} Pr(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) &= \text{Norm}_{\mathbf{x}}[\boldsymbol{\mu}, \boldsymbol{\Sigma}], \\ Pr(\boldsymbol{\epsilon}|\mathbf{0}, \sigma^2\mathbf{I}) &= \text{Norm}_{\boldsymbol{\epsilon}}[\mathbf{0}, \sigma^2\mathbf{I}] \end{aligned}$$

siendo independientes \mathbf{x} y $\boldsymbol{\epsilon}$

entonces

$$Pr(\mathbf{y}) = \text{Norm}_{\mathbf{y}}[\mathbf{A}\boldsymbol{\mu}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T + \sigma^2\mathbf{I}]$$

II. De Distribuciones Gaussianas a Procesos Gaussianos

Supongamos que las filas de \mathbf{X} contienen los rasgos de nuestras muestras. Tenemos n muestras y cada una de ellas tiene q componentes

The diagram illustrates a matrix \mathbf{X} of size $n \times q$. The matrix is represented as a large square bracket containing elements $x_{1,1}, \dots, x_{1,q}$ in the first row, $x_{n,1}, \dots, x_{n,q}$ in the last row, and $x_{i,1}, \dots, x_{i,q}$ in the i -th row. The i -th row is highlighted with a pink background and a red arrow points to it from the label $\mathbf{x}_{i,:}^\top$. The j -th column is highlighted with a green background. A blue arrow points from the label 'Rasgos de la i-ésima muestra' to the i -th row. A blue arrow points from the label 'Fila completa' to the i -th row.

$$\mathbf{X} = \begin{bmatrix} x_{1,1} & \cdots & x_{1,j} & \cdots & x_{1,q} \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ x_{i,1} & \cdots & x_{i,j} & \cdots & x_{i,q} \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ x_{n,1} & \cdots & x_{n,j} & \cdots & x_{n,q} \end{bmatrix} \rightarrow \mathbf{x}_{i,:}^\top$$

Rasgos de la i-ésima muestra

Fila completa

$$\mathbf{x}_{i,:} \in \mathcal{X} = \mathcal{R}^q$$

II. De Distribuciones Gaussianas a Procesos Gaussianos

Escribimos

$$p(\mathbf{f}|\mathbf{x}) = \mathcal{N}(\mathbf{f}|\mathbf{0}, \mathbf{K}_{ff}) = (2\pi)^{-\frac{n}{2}} |\mathbf{K}_{ff}|^{-\frac{1}{2}} \exp\left(-\frac{1}{2}\mathbf{f}^\top \mathbf{K}_{ff}^{-1}\mathbf{f}\right)$$

Casi sería mejor utilizar aquí mayúscula para \mathbf{x} .

La matriz de covarianzas

$$\mathbf{K}_{ff} = (k_f(\mathbf{x}_{i,:}, \mathbf{x}_{j,:}))$$

- se construye evaluando la función k_f sobre las parejas de muestras. Tiene tamaño $n \times n$.
- Tiene que ser semidefinida positiva para cualquier número n y cualquier conjunto de vectores de rasgos.

II. De Distribuciones Gaussianas a Procesos Gaussianos

Observa que deberíamos escribir, incluyendo los parámetros desconocidos de la función de covarianza (núcleo),

$$p(\mathbf{f}|\mathbf{x}, \boldsymbol{\theta}_f)$$

Obviamente, una de las tareas durante el aprendizaje será aprender los parámetros del núcleo

II. De Distribuciones Gaussianas a Procesos Gaussianos

Ejemplo

$$\mathcal{X} = \mathcal{R}$$

$$\mathbf{X} = \begin{bmatrix} -2 \\ -1.8 \\ \vdots \\ 1.8 \\ 2 \end{bmatrix} \leftarrow \mathbf{x}_{2,:}$$

Fíjate que son números pero las filas podrían ser vectores.

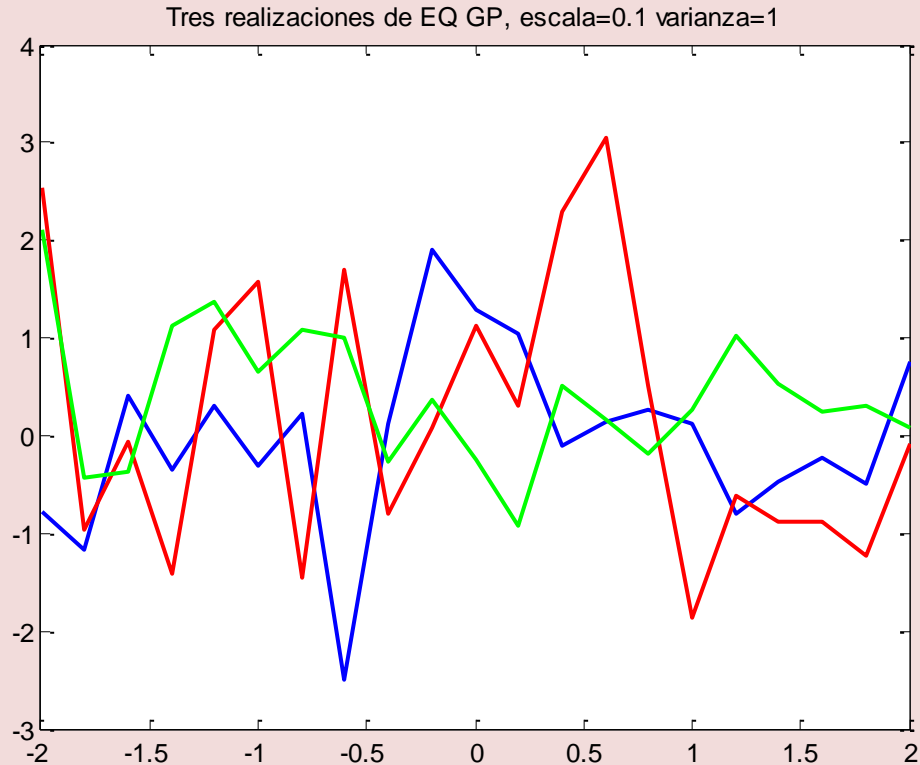
$$\mathbf{K}_{ff} = (k_f(\mathbf{x}_{i,:}, \mathbf{x}_{j,:})) = (\text{var} \times \exp[-\frac{1}{sc^2} \|\mathbf{x}_{i,:} - \mathbf{x}_{j,:}\|^2])$$

Exponentiated quadratic (EQ) covarianza. También se le llama RBF o núcleo Gaussiano

II. De Distribuciones Gaussianas a Procesos Gaussianos

% poco eficiente pero fácil de entender

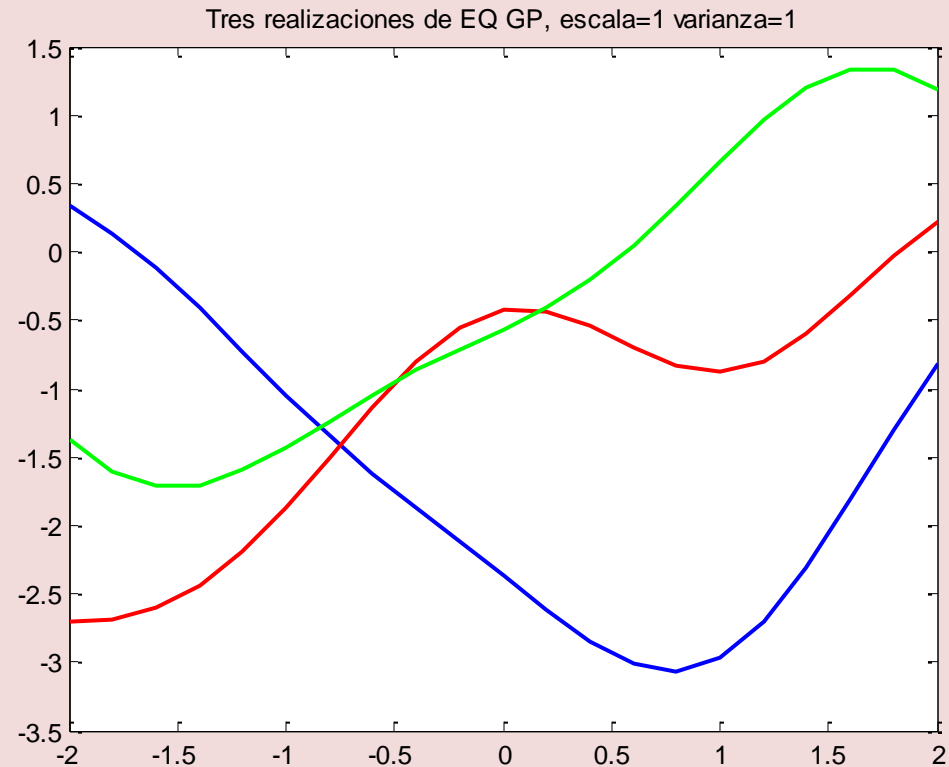
```
sc=0.1; var=1;  
X=-2:.2:2;  
[U,V] = meshgrid(X,X);  
Sigma = var*exp(-(1/(2*sc*sc))*(U-V).^2);  
mean=zeros(1,numel(X));  
  
sample=mvnrnd(mean,Sigma,1);  
plot([-2:.2:2],sample,'b','LineWidth',2)  
  
sample=mvnrnd(mean,Sigma,1);  
hold on;plot([-2:.2:2],sample,'r','LineWidth',2)  
  
sample=mvnrnd(mean,Sigma,1);  
hold on; plot([-2:.2:2],sample,'g','LineWidth',2)  
  
title(['Tres realizaciones de EQ GP, escala=',num2str(sc),' varianza=',num2str(var)])
```



II. De Distribuciones Gaussianas a Procesos Gaussianos

% poco eficiente pero fácil de entender

```
sc=1; var=1;  
X=-2:.2:2;  
[U,V] = meshgrid(X,X);  
Sigma = var*exp(-(1/(2*sc*sc))*(U-V).^2);  
mean=zeros(1,numel(X));  
  
sample=mvnrnd(mean,Sigma,1);  
plot([-2:.2:2],sample,'b','LineWidth',2)  
  
sample=mvnrnd(mean,Sigma,1);  
hold on;plot([-2:.2:2],sample,'r','LineWidth',2)  
  
sample=mvnrnd(mean,Sigma,1);  
hold on; plot([-2:.2:2],sample,'g','LineWidth',2)  
  
title(['Tres realizaciones de EQ GP, escala=',num2str(sc),' varianza=',num2str(var)]);
```



II. De Distribuciones Gaussianas a Procesos Gaussianos

% poco eficiente pero fácil de entender

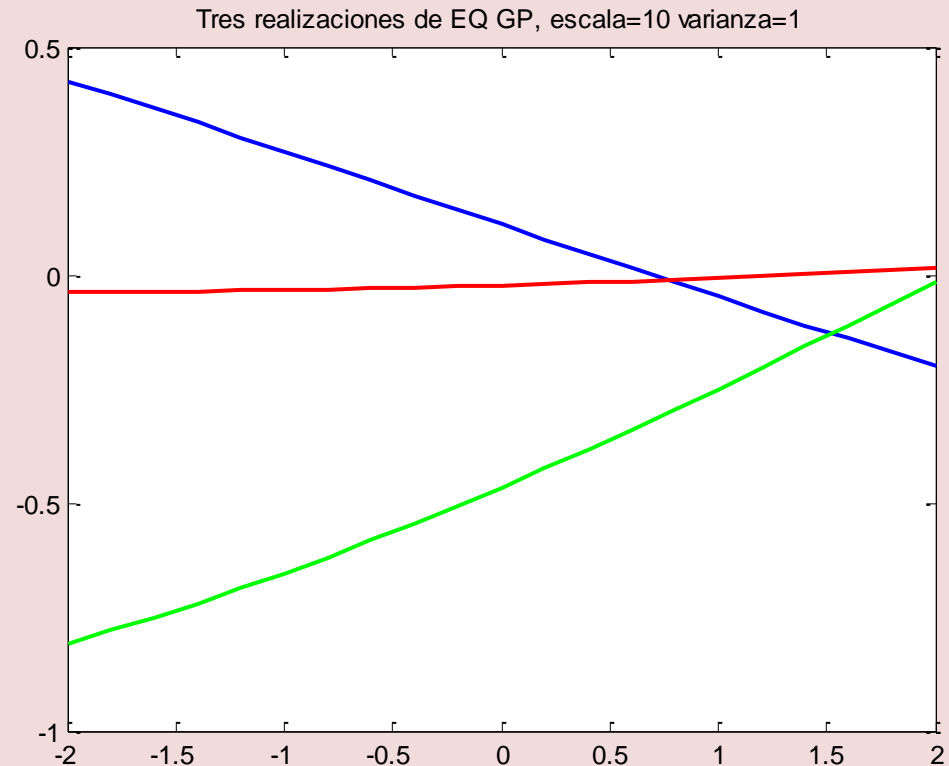
```
sc=10; var=1;  
X=-2:.2:2;  
[U,V] = meshgrid(X,X);  
Sigma = var*exp(-(1/(2*sc*sc))*(U-V).^2);  
mean=zeros(1,numel(X));
```

```
sample=mvnrnd(mean,Sigma,1);  
plot([-2:.2:2],sample,'b','LineWidth',2)
```

```
sample=mvnrnd(mean,Sigma,1);  
hold on;plot([-2:.2:2],sample,'r','LineWidth',2)
```

```
sample=mvnrnd(mean,Sigma,1);  
hold on; plot([-2:.2:2],sample,'g','LineWidth',2)
```

```
title(['Tres realizaciones de EQ GP, escala=',num2str(sc),' varianza=',num2str(var)]);
```



II. De Distribuciones Gaussianas a Procesos Gaussianos

En situaciones reales se supone que sólo disponemos de observaciones ruidosas y escribiremos

$$\mathbf{y} = f(\mathbf{x}) + \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \beta^{-1}\mathbf{I})$$

que induce la verosimilitud

$$p(\mathbf{y}|\mathbf{f}) = \mathcal{N}(\mathbf{y}|\mathbf{f}, \beta^{-1}\mathbf{I})$$

y da lugar a la marginal (a utilizar para aprendizaje, training)

$$p(\mathbf{y}|\mathbf{x}) = \int p(\mathbf{y}|\mathbf{f})p(\mathbf{f}|\mathbf{x})d\mathbf{f} = \mathcal{N}(\mathbf{y}|\mathbf{0}, \mathbf{K}_{ff} + \beta^{-1}\mathbf{I})$$

que será utilizada para aprender los parámetros del modelo, es decir, los parámetros de la covarianza y β .

II. De Distribuciones Gaussianas a Procesos Gaussianos

La distribución predictiva (**a utilizar para prueba, test**) para una colección n_* de input de prueba \mathbf{x}_*

$$p(\mathbf{f}_* | \mathbf{y}, \mathbf{x}, \mathbf{x}_*) = \mathcal{N}(\mathbf{f}_* | \mathbf{L}\mathbf{y}, \mathbf{K}_{**} - \mathbf{L}\mathbf{K}_{f*})$$

donde

$$\mathbf{L} = \mathbf{K}_{*f}(\mathbf{K}_{ff} + \beta^{-1}\mathbf{I})^{-1}$$

$$\mathbf{K} = \begin{bmatrix} \mathbf{K}_{ff} & \mathbf{K}_{f*} \\ \mathbf{K}_{*f} & \mathbf{K}_{**} \end{bmatrix}$$

es la matriz de covarianza asociada a la matriz de rasgos de la derecha

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{X}_* \end{bmatrix}$$

¿De dónde sale la fórmula?

II. De Distribuciones Gaussianas a Procesos Gaussianos

Demostración de la **MUY IMPORTANTE** fórmula de la distribución condicionada en la diapositiva anterior. Sabemos que

$$p(\mathbf{f}_*|\mathbf{f}) = \mathcal{N}(\mathbf{f}_*|\mathbf{K}_{*f}\mathbf{K}_{ff}^{-1}\mathbf{f}, \mathbf{K}_{**} - \mathbf{K}_{*f}\mathbf{K}_{ff}\mathbf{K}_{f*})$$

$$\begin{aligned} p(\mathbf{f}|\mathbf{y}) &= \mathcal{N}(\mathbf{f} | (\mathbf{K}_{ff}^{-1} + \beta\mathbf{I})^{-1}\beta\mathbf{y}, (\mathbf{K}_{ff}^{-1} + \beta\mathbf{I})^{-1}) \\ &= \mathcal{N}(\mathbf{f} | (\beta^{-1}\mathbf{K}_{ff}^{-1} + \mathbf{I})^{-1}\mathbf{y}, (\mathbf{K}_{ff}^{-1} + \beta\mathbf{I})^{-1}) \end{aligned}$$

De donde obtenemos

$$\begin{aligned} p(\mathbf{f}_*|\mathbf{y}) &= \int p(\mathbf{f}_*|\mathbf{f})p(\mathbf{f}|\mathbf{y})d\mathbf{f} \\ &= \mathcal{N}(\mathbf{f}_* | K_{*f}(K_{ff} + \beta^{-1}\mathbf{I})^{-1}\mathbf{y}, \\ &\quad K_{**} - K_{*f}K_{ff}^{-1}K_{f*} + K_{*f}K_{ff}^{-1}(K_{ff}^{-1} + \beta^{-1}\mathbf{I})^{-1}K_{ff}^{-1}K_{f*} \end{aligned}$$

II. De Distribuciones Gaussianas a Procesos Gaussianos

Una de las grandes ventajas del uso de GP es la tratabilidad de su marginal

$$p(\mathbf{y}|\mathbf{x}) = \int p(\mathbf{y}|\mathbf{f})p(\mathbf{f}|\mathbf{x})d\mathbf{f} = \mathcal{N}(\mathbf{y}|\mathbf{0}, \mathbf{K}_{ff} + \beta^{-1}\mathbf{I})$$

$$p(\mathbf{y}|\mathbf{x}) = (2\pi)^{-\frac{n}{2}} \underbrace{|\mathbf{K}_{ff} + \beta^{-1}\mathbf{I}|^{-\frac{1}{2}}}_{\text{Nos gustaría que fuese grande}} \exp \left(-\frac{1}{2} \mathbf{y}^\top \underbrace{(\mathbf{K}_{ff} + \beta^{-1}\mathbf{I})^{-1}}_{\text{Nos gustaría que fuese pequeño}} \mathbf{y} \right)$$


Nos gustaría que fuese grande

Nos gustaría que fuese pequeño


- La matriz de covarianza seleccionada decide las propiedades y no la forma paramétrica de f .
- El tamaño de la matriz de covarianzas nos generará problemas si tenemos que calcular su inversa.

II. De Distribuciones Gaussianas a Procesos Gaussianos


- La media del GP se representa como una curva en negro, dos desviaciones estándar se muestran con una sombra de gris.
- Las muestras se dibujan con diferentes colores.




(a) Muestras de la a priori



(b) Muestras de la a posteriori



(c) Igual que (b) pero con más varianza del ruido




(d) Muestras de la a posteriori pero con más observaciones

Observa:

- Más ruido, más incertidumbre en la a posteriori, (b) y (c).
- Efecto de tener más observaciones, (d).
- La media vuelve a cero lejos de las observaciones.

II.1 Funciones de Covarianza

Vamos a ver varios ejemplos de matrices de covarianza.
Recuerda la notación



$k_f(\mathbf{x}_{i,:}, \mathbf{x}_{k,:})$ es semidefinida positiva sobre todos los posibles pares de entradas

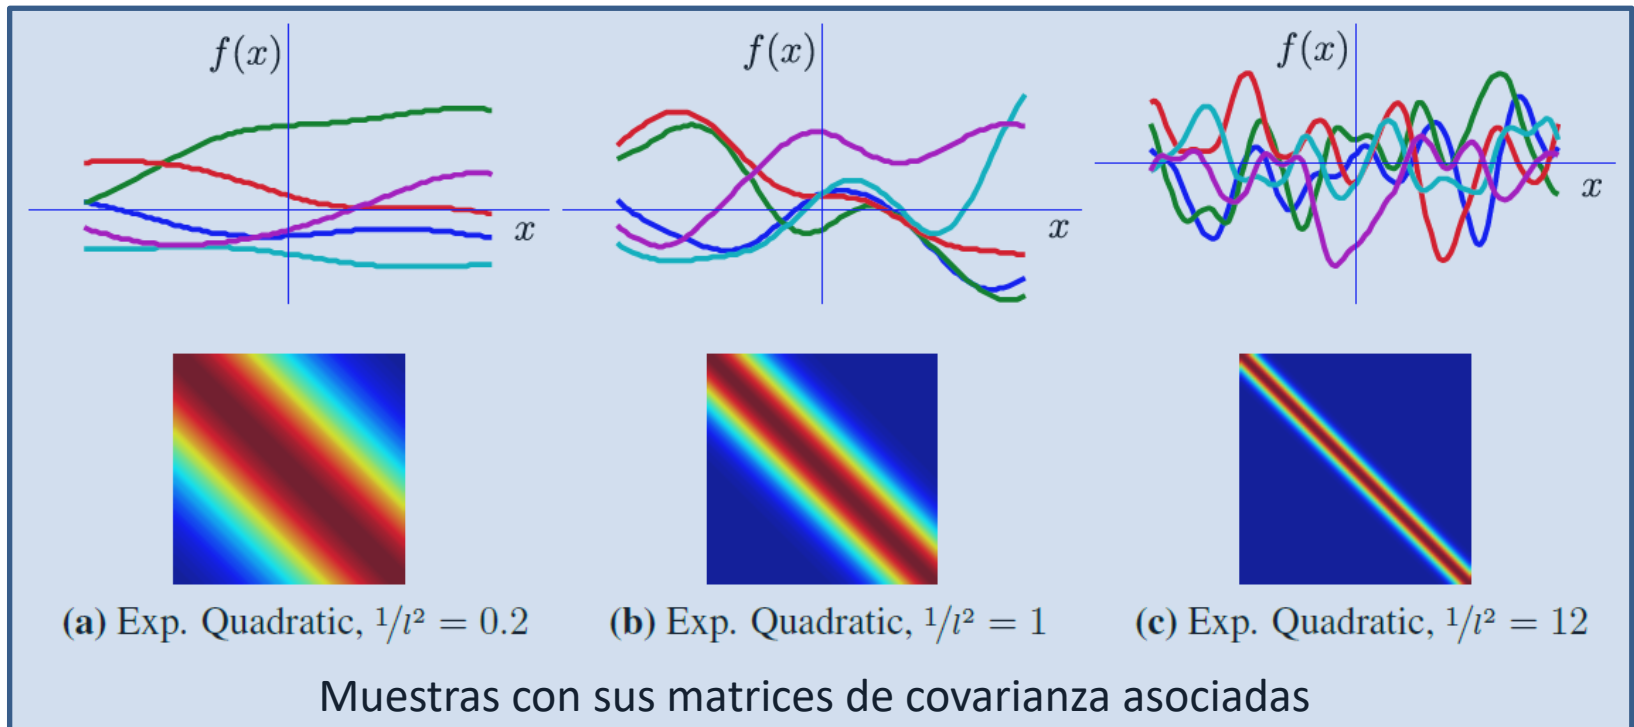
II.1 Funciones de Covarianza

Exponentiated quadratic (EQ), también llamada RBF.

$$k_{f(\text{EQ})}(\mathbf{x}_{i,:}, \mathbf{x}_{k,:}) = \sigma_{\text{EQ}}^2 \exp \left(-\frac{1}{2\ell^2} \sum_{j=1}^q (x_{i,j} - x_{k,j})^2 \right)$$

↑
Varianza y Longitud de escala (ℓ^2)

Observa que $x_{i,:}$ pueden ser las coordenadas 2-D de un píxel



II.1 Funciones de Covarianza

Exponentiated quadratic (EQ), con pesos diferentes para las distintas dimensiones de los inputs.

Permitirá Automatic Relevance Determination (ARD)

$$k_{f(\text{ARD})}(\mathbf{x}_{i,:}, \mathbf{x}_{k,:}) = \sigma_{\text{ARD}}^2 \exp \left(-\frac{1}{2} \sum_{j=1}^q \underset{\uparrow}{w_j} (x_{i,j} - x_{k,j})^2 \right)$$

Pesos. Pequeños, dimensiones no relevantes.
Grandes, dimensiones relevantes

Lineal ARD función de covarianza.

$$k_{f(\text{lin})}(\mathbf{x}_{i,:}, \mathbf{x}_{k,:}) = \sigma_{\text{lin}}^2 \mathbf{x}_{i,:}^{\top} \mathbf{C} \mathbf{x}_{k,:}$$

C es una matriz diagonal que contiene los pesos ARD.

II.1 Funciones de Covarianza

Matérn 3/2

$$k_{f(\text{mat})}(\mathbf{x}_{i,:}, \mathbf{x}_{k,:}) = \sigma_{\text{mat}}^2 \left(1 + \frac{\sqrt{3}|\mathbf{x}_{i,:} - \mathbf{x}_{k,:}|}{\ell} \right) \exp \left(\frac{-\sqrt{3}|\mathbf{x}_{i,:} - \mathbf{x}_{k,:}|}{\ell} \right)$$

EQ-periodic

$$k_{f(\text{per})}(x_i, x_j) = \sigma_{\text{per}}^2 \exp \left(-\frac{1}{\ell^2} 2 \sin^2 \left(\frac{\pi}{T} |x_i - x_j| \right) \right)$$



Se aplica a cada componente y luego el resultado se lleva a un EQ.

Ruido



$$k_{\text{white}}(\mathbf{x}_{i,:}, \mathbf{x}_{k,:}) = \theta_{\text{white}} \delta_{i,k}$$

Parece muy tonta pero aparece frecuentemente en problemas relacionados con diccionarios



II.1 Funciones de Covarianza



(d) Matérn $3/2$



(e) EQ-Periodic



(f) EQ plus EQ-Periodic

III Interpretación de un GP a través de un modelo generativo

Consideremos el modelo lineal

$$\mathbf{y} = \begin{bmatrix} f_1 \\ \vdots \\ f_n \end{bmatrix}_{n \times 1} = \boldsymbol{\mu} \mathbf{1}_{n \times 1} + \begin{bmatrix} \mathbf{x}_{1,:}^T \\ \vdots \\ \mathbf{x}_{n,:}^T \end{bmatrix}_{n \times q} \mathbf{w}_{q \times 1} + \boldsymbol{\epsilon}$$

$\mathbf{X} \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \beta^{-1} \mathbf{I}_{n \times n})$

y, muy importante, consideramos la distribución esférica

$$\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_{q \times q})$$

III Interpretación de un GP a través de un modelo generativo

Si integramos en w y el error tenemos

$$\mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}\mathbf{1}, \mathbf{X}\mathbf{X}^T + \beta^{-1}\mathbf{I})$$

III Interpretación de un GP a través de un modelo generativo

¿Y si hacemos la siguiente transformación?

$$\mathbf{x}_{i,:}^T = (x_{i1}, x_{i2}, \dots, x_{iq}) \xrightarrow{\phi}$$

$$\mathbf{z}_{i,:}^T = \phi(\mathbf{x}_{i,:}^T) = (\phi_1(x_{i,:}^T) \quad \phi_2(x_{i,:}^T) \quad \dots \quad \phi_{q'}(x_{i,:}^T))$$

Observa que las dimensiones de un vector de rasgos y su transformado pueden no ser las mismas. **La dimensión q' puede ser infinito!!!**

III Interpretación de un GP a través de un modelo generativo

Podríamos hacer, por ejemplo, la siguiente transformación

$$\mathbf{x}^T = \begin{pmatrix} x_1 & x_2 \end{pmatrix} \xrightarrow{\phi}$$

$$\mathbf{z} = \phi(\mathbf{x}^T) = \begin{pmatrix} x_1 & x_2 & x_1x_2 & x_1^2 & x_2^2 \end{pmatrix}$$

Observa que las dimensiones de un vector de rasgos y su transformado pueden no ser las mismas.

III Interpretación de un GP a través de un modelo generativo

Pasaríamos de

$$\mathbf{y} = \begin{bmatrix} f_1 \\ \vdots \\ f_n \end{bmatrix}_{n \times 1} = \boldsymbol{\mu} \mathbf{1}_{n \times 1} + \begin{bmatrix} \mathbf{x}_{1,:}^T \\ \vdots \\ \mathbf{x}_{n,:}^T \end{bmatrix}_{n \times q} \mathbf{w}_{q \times 1} + \boldsymbol{\epsilon}$$

$$\begin{array}{l} \mathbf{X} \\ \mathbf{w} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_{q \times q}) \\ \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_{n \times n}) \end{array}$$

a

$$\mathbf{y} = \begin{bmatrix} f_1 \\ \vdots \\ f_n \end{bmatrix}_{n \times 1} = \boldsymbol{\mu}' \mathbf{1}_{n \times 1} + \begin{bmatrix} \mathbf{z}_{1,:}^T \\ \vdots \\ \mathbf{z}_{n,:}^T \end{bmatrix}_{n \times q'} \mathbf{w}_{q' \times 1} + \boldsymbol{\epsilon}'$$

$$\begin{array}{l} \mathbf{Z} \\ \mathbf{w} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_{q' \times q'}) \\ \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, (\beta')^{-1} \mathbf{I}_{n \times n}) \end{array}$$

III Interpretación de un GP a través de un modelo generativo

y si integramos en w y el nuevo error

$$\mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}'\mathbf{1}, \mathbf{Z}\mathbf{Z}^T + (\beta')^{-1}\mathbf{I})$$

Este modelo nos indica que sólo necesitamos conocer el producto escalar de los vectores transformados en el dominio transformado.

La matriz $\mathbf{Z}\mathbf{Z}^T$ es semidefinida positiva y corresponderá a una matriz de la forma

$$\mathbf{K}_{ff} = (k_f(\mathbf{x}_{i,:}, \mathbf{x}_{j,:}))$$

III Interpretación de un GP a través de un modelo generativo


¿Qué hace, por tanto, un GP?

$$\mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}'\mathbf{1}, \mathbf{Z}\mathbf{Z}^T + (\beta')^{-1}\mathbf{I})$$


- Como modelo generativo, representar linealmente nuestros datos en un dominio transformado de los rasgos.
- No necesitamos conocer en que vectores se transforman los rasgos. Sólo el producto escalar en el dominio transformado. Es decir, el núcleo asociado.

$$\mathbf{K}_{ff} = (k_f(\mathbf{x}_{i,:}, \mathbf{x}_{j,:}))$$

Bibliografía



<http://www.computervisionmodels.com/>





<http://research.microsoft.com/en-us/um/people/cmbishop/prml/>

Bibliografía

<http://www.cs.ubc.ca/~murphyk/MLbook/>

<http://www.inference.phy.cam.ac.uk/mackay/itila/>



<http://www.cs.ucl.ac.uk/staff/d.barber/brml/>