



ugr

Universidad
de Granada



DECSAI
Universidad de Granada

2.1 Redes Neuronales Artificiales

Redes Neuronales FeedForward

Haga clic para
agregar texto

M^a Carmen Pegalajar

mcarmen@decsai.ugr.es

*Depto de Ciencias de la Computación e IA
Universidad de Granada*

Contenidos

1. Perceptron
2. Adaline
3. Redes Multicapa

1. Perceptron


1.1 Conceptos Básicos

- Perceptrón es la red neuronal más simple (Rosenblatt(1957))
- Una sola capa con tantas neuronas como salidas se precisen.
 - Cada neurona tiene tantas entradas como la dimensión del patrón de entrada
 - Función de activación: Función Umbral
 - Entrada Neta: suma de las entradas ponderadas por los pesos

1.2 El Perceptron Simple

Un Perceptrón simple consta de :


- Una sola neurona
- Dos entradas reales y una salida binaria (-1/1).
- Función de activación umbral (-1,1) y bias $= \theta$



1.3 Interpretación Geométrica

- La salida de la unidad es:
 - Si $w_1 * x_1 + w_2 * x_2 \geq \theta$ entonces $y=1$
 - Si $w_1 * x_1 + w_2 * x_2 < \theta$ entonces $y=-1$
- Interpretaremos la ecuación como la ecuación de una recta:
 - $w_1 * x_1 + w_2 * x_2 - \theta = 0$

1.4 Interpretación Gráfica



1.5 El Algoritmo de Entrenamiento

1.5.1 Deducción Intuitiva

- Supongamos una entrada a la neurona con un valor positivo:
 - Si la neurona responde con -1 y debiera responder con 1, debemos incrementar el peso correspondiente.
 - Si la neurona responde con +1, y debiera responder con -1, se decrementará el peso correspondiente.
- Si la entrada es negativa, el razonamiento es a la inversa


1.6 Teorema de convergencia

- ▣ Si las clases son **linealmente separables**, el algoritmo del Perceptrón converge a una solución correcta en un **número finito de pasos** para cualquier elección inicial de pesos.
- ▣ Lamentablemente, para la mayoría de los problemas, ese conjunto de valores no existe.

2. Adaline

2.1 Adaline vs. Perceptrón

- En el mismo tiempo que Rosenblatt, Widrow y su estudiante Hoff trabajaron en Adaline



Widrow y Hoff
(aprox. 1960)

2.2 Aprendizaje: la regla delta

- Si la función de activación es la identidad:

$$y = \sum_j w_j \cdot x_j$$

- Si N es el número de patrones, podemos definir el error total cometido como:

$$E = \frac{1}{2} \sum_{p=1}^N (d^p - y^p)^2$$

- Aplicaremos el algoritmo iterativo de descenso del gradiente:

$$w_j = w_j - \alpha \frac{\partial E}{\partial w_j}$$

2.2 Aprendizaje: la regla delta

- ▣ Para calcular el valor de la derivada con respecto de cada peso:

$$\frac{\partial E}{\partial w_j} = \frac{\partial E}{\partial y} \cdot \frac{\partial y}{\partial w_j} = -(d - y) \cdot x_j$$

- ▣ Por lo que la modificación de los pesos es:

$$\Delta w_j = \alpha \cdot (d - y) \cdot x_j$$

- ▣ Esta regla se denomina **Regla Delta** o **Widrow-Hoff**

2.3 Algoritmo LMS

1. Asignar valores aleatorios a los pesos
2. Aplicar un vector de entrada y obtener la salida correspondiente:

$$\text{Salida_Obtenida} = F(W * X)$$

$$\text{Error} = \text{salida_deseada} - \text{salida_obtenida}$$

$$w_i = w_i + \alpha * \text{error} * X_i, \text{ para todo } i$$

3. Volver al paso 2

2.4 Diferencias perceptrón vs. Adaline

- Adaline calcula el error a partir de la entrada neta y el perceptron utiliza la salida en base a un umbral.
- El error total de Adaline casi nunca será nulo, su condición de terminación suele ser:
$$\text{Error}(t) - \text{Error}(t-1) < \epsilon$$
- Aparece el parámetro **tasa de aprendizaje, α** .
- Se suelen obtener buenos resultados con una tasa de aprendizaje de 0.1
- Para problemas linealmente separables, produce un error mínimo según LMS

3. Redes Multicapa

3.1 Introducción

- Las redes monocapa sólo dan solución a problemas linealmente separables
- La mayoría de los problemas del mundo real no son linealmente separables.
- La solución está en añadir más capas?.




Figura A.9. Estructura de la red de propagación hacia atrás (Nilsson, 2001).

3.1 Introducción

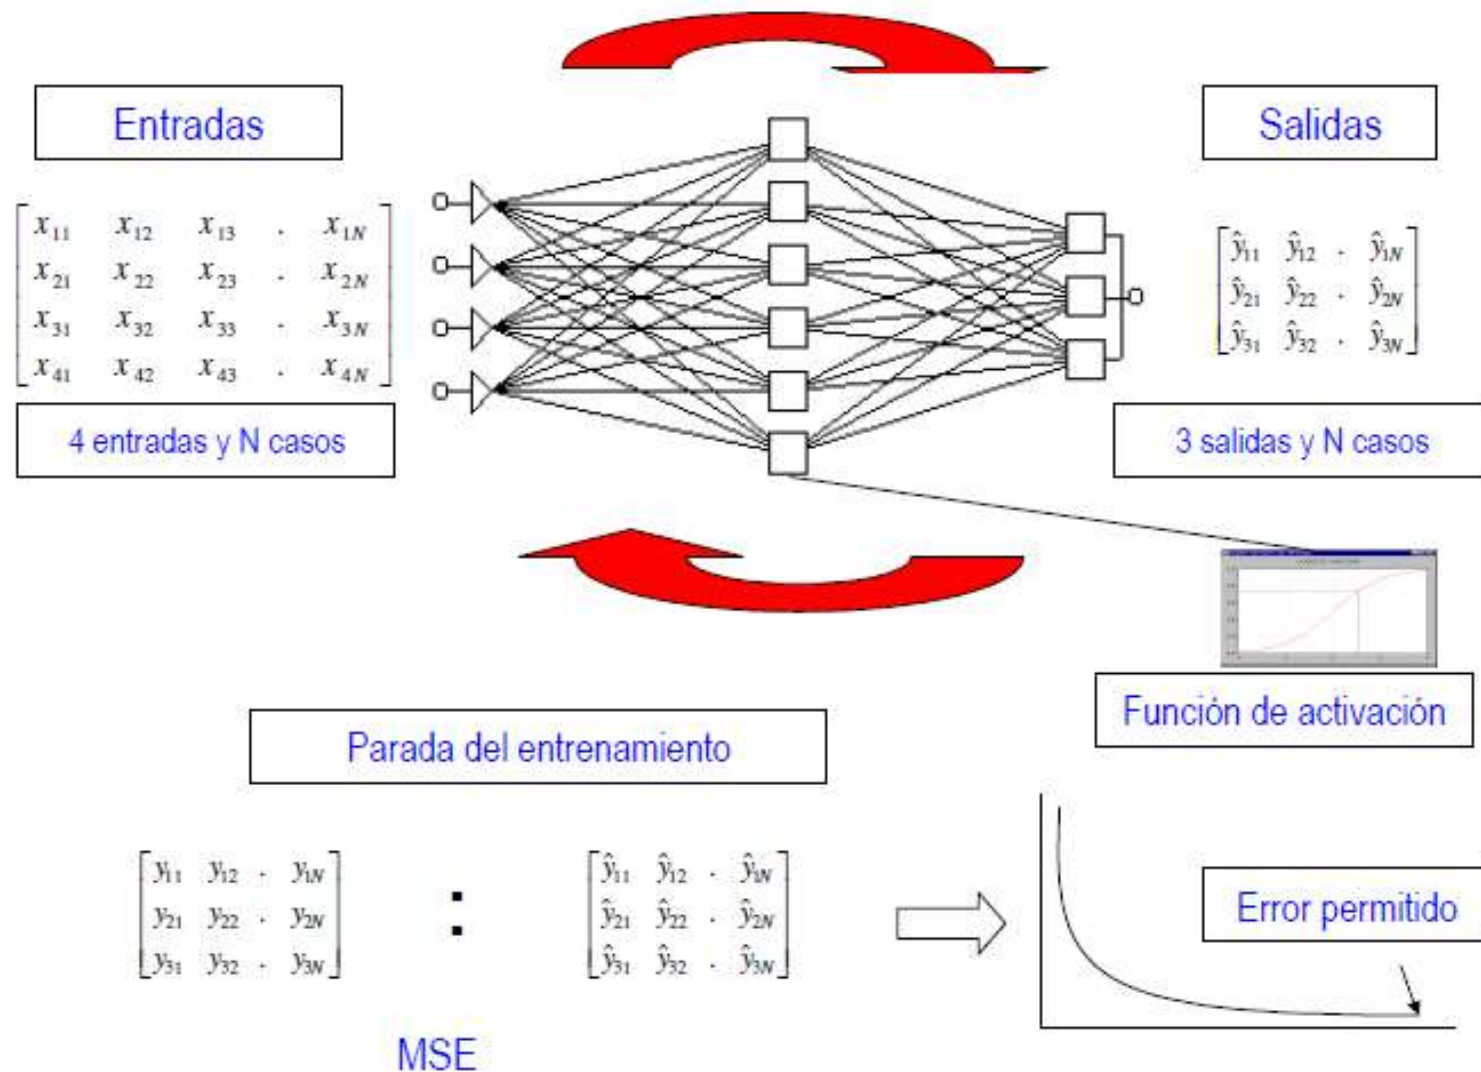
- Cualquier red multicapa cuyas funciones sean lineales se pueden reducir a una red monocapa lineal
- Hay que utilizar funciones no lineales
- La red multicapa es capaz de aproximar cualquier función, siempre que las funciones de activación sean no lineales.

3.2 Algoritmo BackPropagation

Principios Básicos

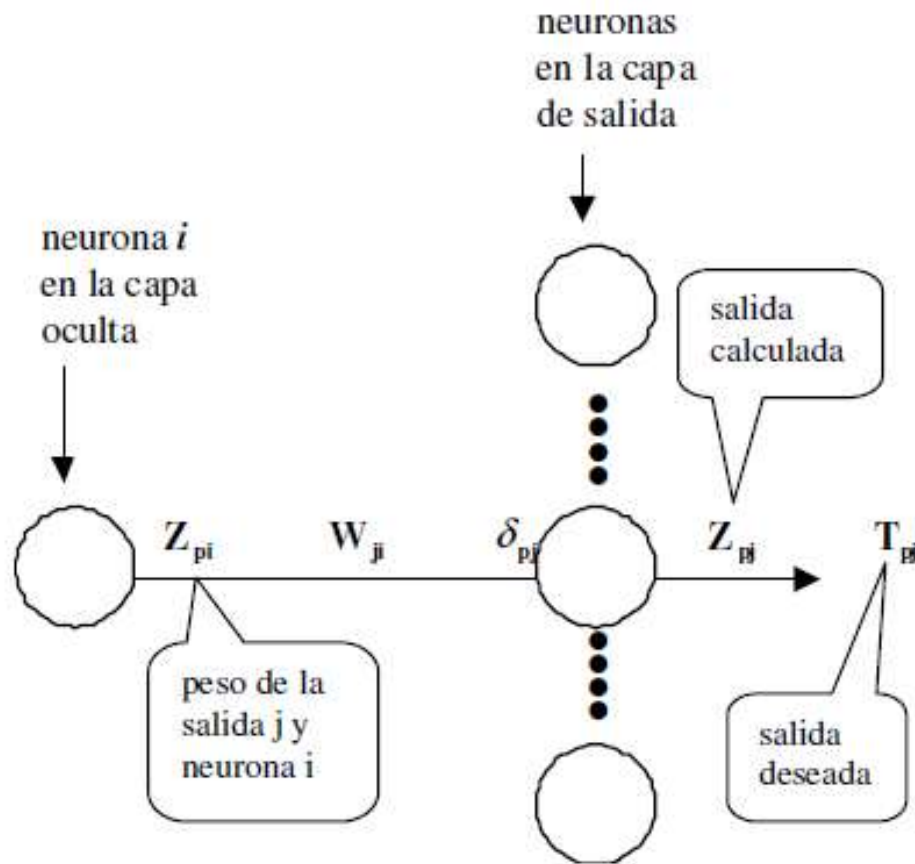
- Calcula el error de salida para cada patrón
- Ajusta los pesos en la capa de salida para reducir el error
- Propaga los errores hacia la capa de entrada, ajustando los pesos de la capa oculta
- Repite este proceso de forma iterativa
- Los pesos pueden actualizarse:
 - Después de presentar cada patrón
 - Tras presentar el conjunto total de entrenamiento

3.2 Algoritmo BackPropagation



3.2 Algoritmo BackPropagation

COMO AJUSTA LOS PESOS DE LA CAPA DE SALIDA:




$$\Delta W_{ji} = \eta \delta_{pj} Z_{pi}, \text{ donde}$$

$$\delta_{pj} = Z_{pj}(1 - Z_{pj})(T_{pj} - Z_{pj})$$

3.2 Algoritmo BackPropagation

COMO AJUSTA LOS PESOS DE LA CAPA OCULTA:



$$\delta_{pj} = Z_{pj}(1 - Z_{pj}) \left(\sum_k \delta_{pk} W_{kj} \right), \text{ y luego } \Delta_p W_{ji} = \eta \delta_{pj} Z_{pi}$$

3.2 Algoritmo BackPropagation


Características Fundamentales

- Busca el mínimo de la función de error a partir de un conjunto de patrones de entrenamiento.
- El algoritmo precisa que la función de activación sea fácilmente diferenciable
- Entrenar consiste en modificar pesos de la red
- Los pesos se modifican hacia la dirección descendente de la función de error
- La red entrenada es capaz de generalizar, clasificando correctamente patrones ruidosos o incompletos.

3.2 Algoritmo BackPropagation

Representación Gráfica

El algoritmo hace que el sistema evolucione en la dirección de la línea de máxima pendiente



3.2 Algoritmo BackPropagation

Problemas Principales con la Pendiente

- La línea de **máxima pendiente** no es siempre la ruta más directa hacia el mínimo de la función de error.
- Puede converger a un **mínimo local**
- Si la **pendiente es escasa**, el entrenamiento es muy lento
- Si la **pendiente es nula**, el entrenamiento se detiene

3.2 Algoritmo BackPropagation

Deficiencias en el entrenamiento

- **Parálisis de la red:** Los pesos toman valores muy grandes, y la red no cambia
- **Mínimos Locales:** La superficie de error está llena de valles y picos. Es difícil localizar el mínimo global de energía, y se suele caer en mínimos locales.
- Dificultad en elegir la **arquitectura de la red** (número de capas, número de unidades en cada, etc), parámetros de aprendizaje (razón de aprendizaje, error aceptable, etc)
- **Aprendizaje Lento**

3.2 Algoritmo BackPropagation

Tasa de Aprendizaje

- El valor de a nos indica cuanto cambian los pesos
- Si a es muy pequeño la velocidad de aprendizaje es muy lenta
- Si el a es grande, aparecen efectos oscilatorios.
- A veces da resultados comenzar con valores altos e ir reduciéndolos poco a poco.
- Otros algoritmos más eficientes:
 - Quickprop
 - Levenberg-Marquardt

4 Otras cuestiones

¿Cómo elegir el número de capas?

TEOREMA DE KOLMOGOROV

- La Corteza Cerebral tiene entre 50-100 capas
- Cualquier **función continua** puede ser aproximada con **única capa oculta**
- Empíricamente, más capas es mejor a veces
- **Más capas** hacen **más fácil** el aprendizaje
- **Más capas** hacen **más lento** procesar una época de entrenamiento.



ugr

Universidad
de Granada



DECSAI
Universidad de Granada

2.3 Redes Neuronales Artificiales. Técnicas de Validación

M^a Carmen Pegalajar

`mcarmen@decsai.ugr.es`

*Depto de Ciencias de la Computación e IA
Universidad de Granada*

1. Introducción. ¿Por qué validar?

- ▣ Para probar el modelo obtenido bajo todas las circunstancias posibles
- ▣ Es imposible disponer de datos de entrenamiento para simular todas las situaciones posibles.
- ▣ Tenemos que ser capaces de obtener un modelo capaz de generalizar a partir de los datos disponibles

Deficiente generalización

La **generalización deficiente** puede venir por:

- **Conjunto de entrenamiento** escaso o no representativo
- Deficiente **representación** de los datos
- **Arquitectura** de red inadecuada (número de capas ocultas y número de nodos en cada capa)
- **Aprendizaje** erróneo (excesivo, posibilidad de mínimos locales, etc)

Duración del entrenamiento

- ¿Cuándo parar de entrenar la red?
 - Si el error alcanza un mínimo
 - Si la tasa de reducción del error es inferior a un cierto valor
 - Tras un cierto número de “épocas”.
- Estos métodos no garantizan una buena generalización
- La validación trata de subsanar este problema

2. Métodos de Validación

- Validación simple
- Validación cruzada (Hold-k-out)
 - Hold-one-out

2.1 Validación simple


- Divide los datos disponibles en tres grupos:
 - Conjunto de datos de entrenamiento (70%)
 - Conjunto de datos de validación (15%)
 - Conjunto de datos de test (15%)
- Se le conoce como el método “hold out”
- Se utiliza para estimar el error de generalización

2.1 Validación simple

- ▣ **Objetivo final:** que el clasificador consiga un error de generalización pequeño
- ▣ **Error de entrenamiento** decrece monótonamente durante la fase de entrenamiento
- ▣ **El error de validación** decrece hasta que crece, indica un *superajuste (overfitting)* entrenamiento debe finalizar cuando se alcance el primer mínimo de la función del error de validación

2.1 Validación simple

Punto óptimo de parada:

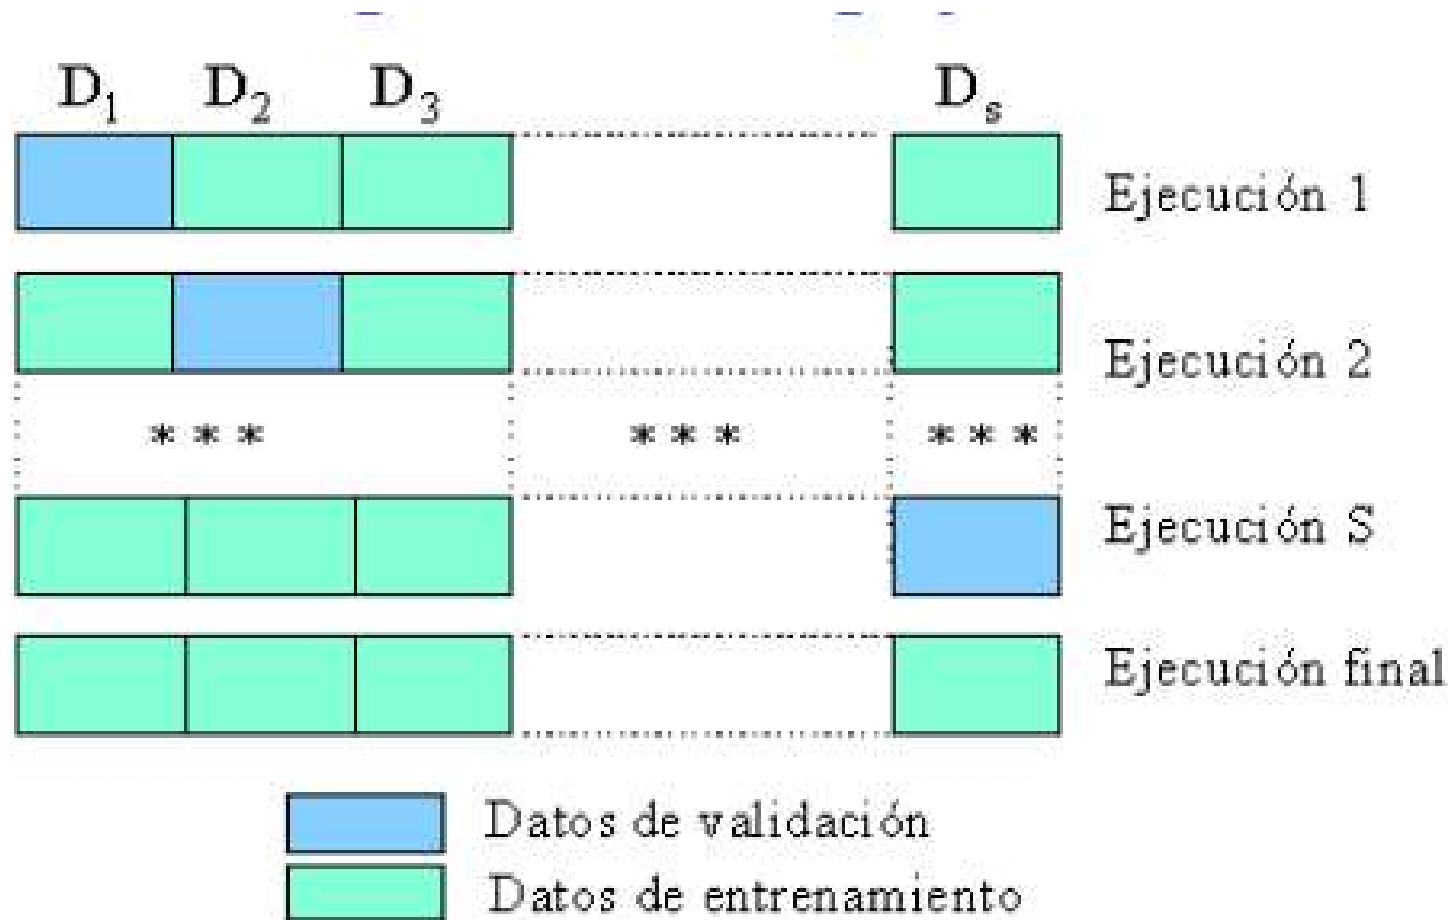


2.2 Validación cruzada (leave-k-out/hold-k-out)

- Procedimiento:
 - Divide los datos de S grupos, de tamaño similar.
 - Un valor típico de S es en torno a 10
 - Entrena a la red S veces, dejando cada vez uno de los conjuntos para validación
- Se puede utilizar para:
 - Calcular el error medio de generalización
 - Entrenar la red, en cuyo caso, se hace al final un entrenamiento con todos los datos disponibles, utilizando los datos de validación obtenidos para detener el entrenamiento prematuramente

2.3 Validación Cruzada

□ Representación gráfica



2.3 Validacion Cruzada

Ventajas e inconvenientes

➤ Ventajas

- Es muy superior a la validación simple con conjuntos de datos pequeños
- Utiliza todos los datos disponibles para entrenar

➤ Inconvenientes

- Precisa $S+1$ entrenamientos (aumento de tiempo)
- El entrenamiento final no utiliza validación directamente)



ugr

Universidad
de Granada



DECSAI
Universidad de Granada

Riesgo de abandono de los Clientes de un Banco

M^a Carmen Pegalajar

mcarmen@decsai.ugr.es

Depto de Ciencias de la Computación e IA

Universidad de Granada

RIESGO DE ABANDONO DE LOS CLIENTES DE UN BANCO

- ❑ Objetivo: predecir si los clientes van a dejar de usar los servicios de un banco o no.
- ❑ El conjunto de datos consta de 10000 observaciones y 14 variables.

IdNumber	CustomerId	Surname	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited
1	15634602	Hargrave	619	France	Female	42	2	0.00	1	1	1	101348.88	1
2	15647311	Hill	608	Spain	Female	41	1	83807.86	1	0	1	112542.58	0
3	15619304	Onio	502	France	Female	42	8	159660.80	3	1	0	113931.57	1
4	15701354	Boni	699	France	Female	39	1	0.00	2	0	0	93826.63	0
5	15737888	Mitchell	850	Spain	Female	43	2	125510.82	1	1	1	79084.10	0

Estudio de neuronas con una capa

	Layers	activation	optimizer	epochs	Precision	Recall	F1	Cohen Kappa
0	[24]	relu	adam	10	0.729167	0.425791	0.537634	0.455066
1	[12]	relu	adam	10	0.775862	0.437956	0.559876	0.483245
2	[6]	relu	adam	10	0.741935	0.391727	0.512739	0.432085
3	[4]	relu	adam	10	0.763636	0.306569	0.437500	0.362437
4	[2]	relu	adam	10	0.779412	0.257908	0.387569	0.317863

Estudio con diferentes capas

	Layers	activation	optimizer	epochs	Precision	Recall	F1	Cohen Kappa
0	[6, 6]	relu	adam	10	0.766949	0.440389	0.559505	0.481822
1	[6, 6, 4]	relu	adam	10	0.728000	0.442822	0.550681	0.467980
2	[6, 6, 4, 2]	relu	adam	10	0.706215	0.304136	0.425170	0.344012
3	[6, 4]	relu	adam	10	0.701818	0.469586	0.562682	0.476417
4	[6, 4, 2]	relu	adam	10	0.751131	0.403893	0.525316	0.445645

Estudio con diferentes algoritmos de entrenamiento

	Layers	activation	optimizer	epochs	Precision	Recall	F1	Cohen Kappa
0	[6, 6]	relu	rmsprop	10	0.704797	0.464720	0.560117	0.474255
1	[6, 6]	relu	sgd	10	0.758475	0.435523	0.553323	0.474549
2	[6, 6]	relu	adagrad	10	0.345679	0.136253	0.195462	0.089685
3	[6, 6]	relu	adadelata	10	0.289883	0.362530	0.322162	0.121536

Ejecuciones con los resultados obtenidos

	Layers	activation	optimizer	epochs	Precision	Recall	F1	Cohen Kappa
0	[24, 12, 6, 4]	tanh	rmsprop	30	0.734848	0.472019	0.574815	0.493377
1	[12, 6, 4, 2]	tanh	rmsprop	30	0.772321	0.420925	0.544882	0.467709
2	[6, 6, 4, 2]	tanh	rmsprop	30	0.801932	0.403893	0.537217	0.463337
3	[12, 6, 4]	tanh	rmsprop	30	0.819048	0.418491	0.553945	0.481943
4	[6, 6, 4]	tanh	rmsprop	30	0.770053	0.350365	0.481605	0.405154
5	[12, 6]	tanh	rmsprop	30	0.764444	0.418491	0.540881	0.462766
6	[6, 6]	tanh	rmsprop	30	0.768844	0.372263	0.501639	0.424472
7	[24, 12, 6, 4]	tanh	sgd	30	0.674847	0.535280	0.597015	0.507474
8	[12, 6, 4, 2]	tanh	sgd	30	0.662011	0.576642	0.616385	0.525618
9	[6, 6, 4, 2]	tanh	sgd	30	0.786026	0.437956	0.562500	0.487068
10	[12, 6, 4]	tanh	sgd	30	0.668831	0.501217	0.573018	0.481780
11	[6, 6, 4]	tanh	sgd	30	0.758333	0.442822	0.559140	0.480411
12	[12, 6]	tanh	sgd	30	0.815534	0.408759	0.544571	0.472136
13	[6, 6]	tanh	sgd	30	0.770213	0.440389	0.560372	0.483087



ugr

Universidad
de Granada



DECSAI
Universidad de Granada

2.6. Lenguas Ópticas inteligentes




M^a Carmen Pegalajar

mcarmen@decsai.ugr.es


*Depto de Ciencias de la Computación e IA
Universidad de Granada*

Lenguas Electrónicas de tipo Óptico.


Podemos definir una lengua electrónica como un instrumento analítico que reproduce de forma artificial la sensación del sabor




Lenguas Electrónicas de tipo Óptico.(2)



1. Un conjunto de sensores químicos



2. Instrumentación para adquirir la señal



3. Algoritmos para procesar la señal

Lengua Óptica Portátil

Tras mostrar el modelo que se desarrolló para la obtención del pH, nos planteamos utilizar dicho modelo en un dispositivo móvil sin la necesidad de utilizar un computador externo.



¿Por qué una lengua óptica en un dispositivo móvil?


La utilización de dispositivos móviles como lenguas electrónicas nos proporciona las siguientes ventajas:

- Rapidez en el análisis
- Bajo precio
- Facilidad de uso
- No tener que tomar muestras previas
- Sin personal entrenado para ello

Matriz de Sensores Ópticos

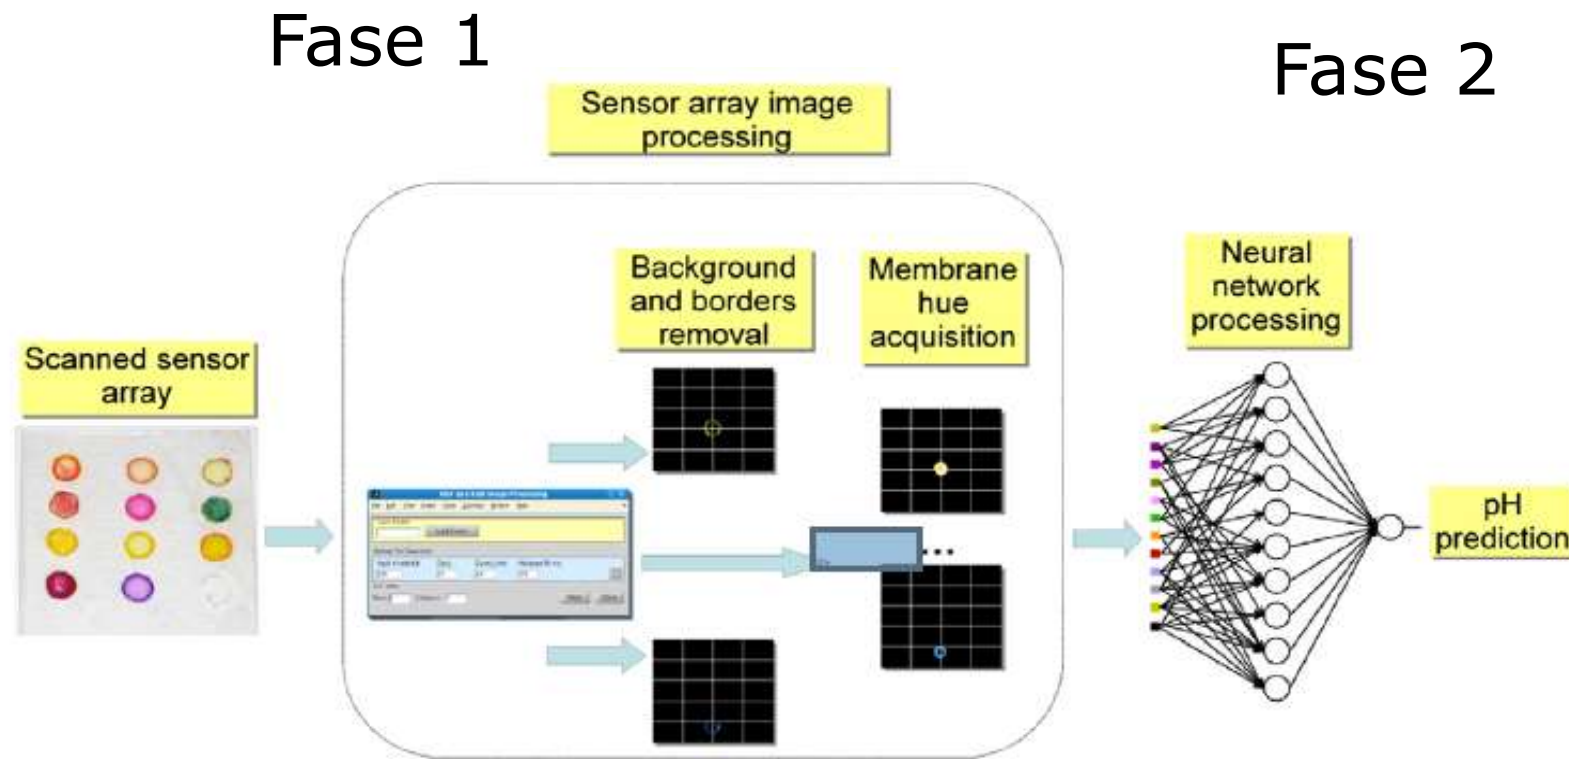
Para la obtención del pH de la disolución se desarrollaron un conjunto de sensores desechables que reaccionan ante la distinta concentración de pH.

Las matrices de sensores son como la siguiente:




Obtención del modelo de Soft Computing

Aquí podemos observar un esquema del modelo utilizado, el cual consta de dos fases:



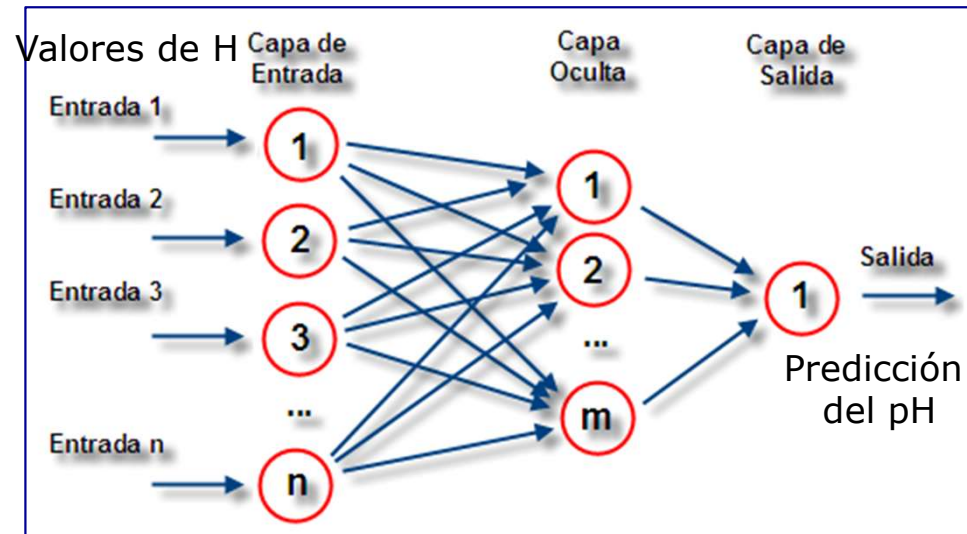
Fase 1: Obtención de los valores HSV

Esta fase consiste en realizar el procesamiento de la imagen para obtener los valores HSV de cada uno de los sensores.



Fase 2: Predicción de pH utilizando Redes Neuronales Artificiales

El modelo utilizado ha sido una red neuronal Perceptrón Multicapa tomando como entradas los valores de H



Parámetros de configuración de la RNA

Número nodos de entrada	11(modos de H de cada sensor)
Número nodos de salida	1 (pH)
Número de capas ocultas	1
Número neuronas capa oculta	10
Función de activación capa oculta	Sigmoide (-1, 1)
Función de activación capa salida	Sigmoide (-1, 1)
Algoritmo de entrenamiento	Levenberg-Marquardt
Función de error	MSE
Normalización datos entrada	[0, 1]
Normalización datos salida	[0.0, 14.0]

REFERENCIAS

- M.M. Erenas, M.C. Pegalajar, M.P. Cuellar, I. de Orbe-Payá, L.F. Capitán-Vallvey, Disposable optical tongue for alkaline ion analysis, Sensors and Actuators B: Chemical, Volume 156, Issue 2, 2011, Pages 976-982, ISSN 0925-4005, <https://doi.org/10.1016/j.snb.2011.03.016>.
- S. Capel-Cuevas, M.P. Cuéllar, I. de Orbe-Payá, M.C. Pegalajar, L.F. Capitán-Vallvey, Full-range optical pH sensor array based on neural networks, Microchemical Journal, Volume 97, Issue 2, 2011, Pages 225-233, ISSN 0026-265X, <https://doi.org/10.1016/j.microc.2010.09.008>.
- S. Capel-Cuevas, MP Cuéllar, M. d. C. Pegalajar, I. de Orbe-Paya y LF Capitan-Vallvey, "Un sistema experto para la predicción del rango de pH completo utilizando una matriz de sensores ópticos desechables", en IEEE Sensors Journal , vol. 12, núm. 5, págs. 1197-1206, mayo de 2012, doi: 10.1109/JSEN.2011.2168815.
- M.M. Erenas, M.C. Pegalajar, M.P. Cuellar, I. de Orbe-Payá, L.F. Capitán-Vallvey, Disposable optical tongue for alkaline ion analysis, Sensors and Actuators B: Chemical, Volume 156, Issue 2, 2011, Pages 976-982, ISSN 0925-4005, <https://doi.org/10.1016/j.snb.2011.03.016>.



ugr

Universidad
de Granada



DECSAI
Universidad de Granada

Redes Neuronales aplicadas a la Edafología

M^a Carmen Pegalajar

`mcarmen@decsai.ugr.es`

Depto de Ciencias de la Computación e IA


Universidad de Granada

Estudio y desarrollo de técnicas de *Soft Computing* aplicadas a la *Edafología* (I).

- ¿Qué es la **Edafología**?
 - Disciplina dentro de la Ciencia del Suelo que se encarga del estudio de la formación, morfología, propiedades y **clasificación del suelo**.
- ¿Dónde nos hemos centrado?
 - En la clasificación del color del suelo, según el **sistema de color Munsell**.
- ¿Por qué hemos escogido el **color** para realizar la clasificación?
 - El color es una propiedad indispensable en la Edafología.
 - Es la propiedad más utilizada en cualquier proceso de clasificación de suelo.
 - A partir del color un edafólogo es capaz de estimar numerosas conclusiones: formación, composición o antigüedad.

Conceptos preliminares (XIII)

Cartas de color de suelo Munsell (II)



Conceptos preliminares (IV)

El problema de la constancia de color (I)

- ❑ Cambios en las propiedades de la fuente de luz provoca cambios en la manera de percibir el color.
- ❑ En una misma escena, bajo condiciones de luz diferentes, percibimos diferencias en los colores.




- ❑ A la capacidad de neutralizar el efecto producido por los cambios en la fuente de luz sobre la percepción del color se le conoce con el nombre de **constancia de color**.

Conceptos preliminares (XII)

Cartas de color de suelo Munsell (I)

- ❑ Representan un subconjunto del total de colores representados en el sistema de color Munsell.
- ❑ En total son **siete cartas de color** asociadas a los *Hues*: 10R, 2.5YR, 5YR, 7.5YR, 10YR, 2.5Y y 5Y.
- ❑ Cada carta posee una serie de muestra de color llamadas normalmente **chips**.
- ❑ Cada chip reproduce de forma estándar un color en concreto (10YR 8/1)
- ❑ En total se tiene un conjunto de **238 chips** de color de suelo.

EJEMPLO CARTA MUNSELL



Descripción de los datos utilizados (I)

Obtención (I)

- Se realizaron una serie de fotografías para obtener los valores RGB asociados a los chips de color de las cartas de suelo Munsell.
- Existen un total de siete cartas de color de suelo Munsell y se han realizado siete fotografías por cada carta y dispositivo.
- Dispositivos utilizados: **Nokia C301**, **Samsung Galaxi S2** y **Canon EOS 1100D**.

	NOKIA	SAMSUN G	CANON	TOTAL
Número Fotograf ías	7	7	7	
Total Chips	238	238	238	
Total Medicio nes (RGB)	1666	1666	1666	4998

Descripción de los datos utilizados (III)

Algoritmo de segmentación de imágenes(II)

- Ejemplo de las siete mediciones devueltas por el algoritmo para el chip 10R 8/4.

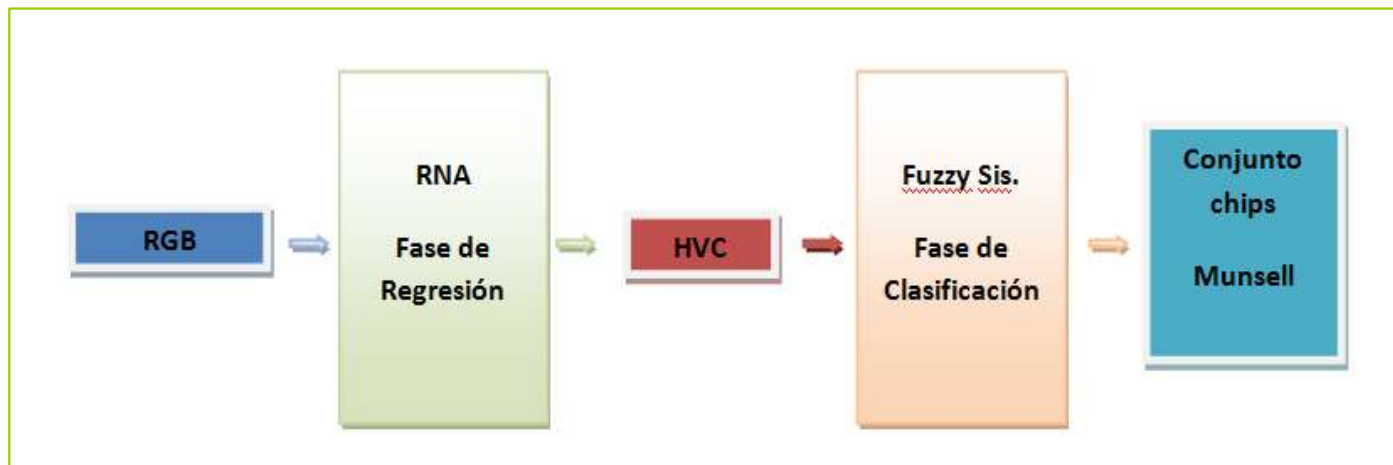
R	G	B
255	216	173
255	210	181
255	227	186
255	214	191
255	215	173
255	209	170
255	224	169

- Estos son los datos utilizados como entradas al sistema.

1ª Opción: RNAs y Sistemas Difusos (I)

Descripción (I)

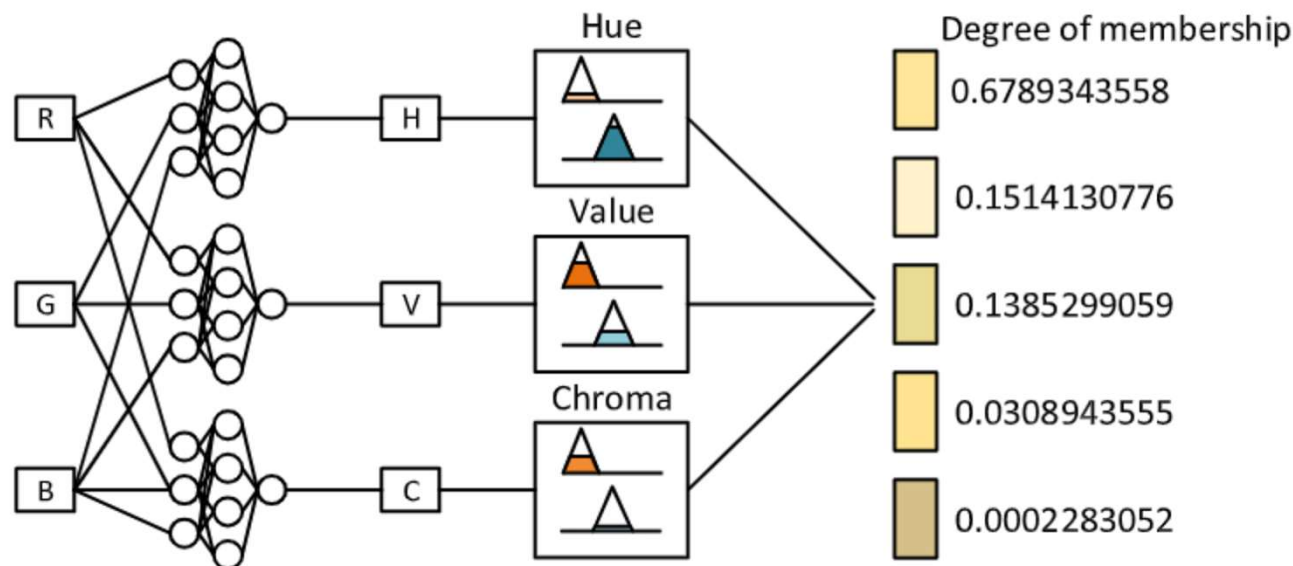
- Uso conjunto de redes de neuronas artificiales y sistemas difusos.
- Solución compuesta por dos fases:
 - **Primera fase:** Calculo de los valores HVC asociados a los valores RGB utilizados como entrada.
 - **Segunda fase:** Clasificación de los chips de color que corresponden a los valores HVC calculados. Uso de sistema difusos.



1ª Opción: RNAs y Sistemas Difusos (III)

Primera Fase (II)- Redes RGB

- ▣ Como entrada reciben las componentes RGB de una medición.
- ▣ Como salida la componente H (V ó C) correspondiente
- ▣ (It was necessary to adapt the possible H values to an equivalent numeric representation 10 (10R), 12.5 (2.5YR), 15 (5YR), 17.5 (7.5YR), 20 (10YR), 22.5 (2.5Y) and 25 (5Y))



1ª Opción: RNAs y Sistemas Difusos (IV)

Primera Fase (III): Redes RGB

- ❑ Se han realizado un total de 50 entrenamientos por red y dispositivo.
- ❑ Se ha elegido la que mejor error de test desnormalizado generaba.
- ❑ Errores de test obtenidos:

	Nokia	Samsung	Canon
Error test H	3.5850	5.2796	1.2082
Error test V	0.0392	0.0331	0.0048
Error test C	0.2593	0.3179	0.0694

1ª Opción: RNAs y Sistemas Difusos (X)

Segunda Fase (I): Sistema difuso

- Esta segunda fase se encarga de:
 - Recibir como entrada los valores HVC calculados en la fase anterior.
 - Devolver como salida el conjunto de chips de las cartas de color de suelo Munsell más cercanos a los valores HVC recibidos como entrada.

Device	Solution A	
	Success (%)	Fail (%)
Canon	94.1176	5.8824
Nokia	76.4706	23.5294
Samsung	73.3193	26.6807

REFERENCIAS

- Solís, M., Muñoz-Alvarado, E., & Pegalajar, M. (2022). The Transformation of RGB Images to Munsell Soil-Color Charts. *Uniciencia*, 36(1), 1-10. <https://doi.org/10.15359/ru.36-1.36>
- M.C. Pegalajar, L.G.B. Ruiz, M. Sánchez-Marañón, L. Mansilla, A Munsell colour-based approach for soil classification using Fuzzy Logic and Artificial Neural Networks, *Fuzzy Sets and Systems*, Volume 401, 2020, Pages 38-54, ISSN 0165-0114, <https://doi.org/10.1016/j.fss.2019.11.002>.
- María Carmen Pegalajar, Manuel Sánchez-Marañón, Luis G Baca Ruíz, Luis Mansilla, Miguel Delgado, *International Conference on Information Processing and Management of Uncertainty in Knowledge-Based Systems*, 699-709, Springer, Cham, 2018.



ugr

Universidad
de Granada



DECSAI
Universidad de Granada

Análisis de Sentimiento mediante Redes Neuronales

M^a Carmen Pegalajar

mcarmen@decsai.ugr.es

*Depto de Ciencias de la Computación e IA
Universidad de Granada*

ANÁLISIS DE SENTIMIENTOS

- ▣ El análisis de sentimientos tiene como objetivo determinar la actitud o el sentimiento ya sea de un orador o escritor con respecto a un documento, interacción o evento.
- ▣ El sentimiento se clasifica principalmente en categorías positivas, negativas y neutras

-
- 50.000 reseñas de películas de usuarios de *IMDB* que están etiquetadas como positivas (1) o negativas (0).
 - Las reseñas están preprocesadas como una secuencia de índices de palabras(enteros).
 - Cada palabra está indexada por su frecuencia general dentro del conjunto de datos. El entero "2" codifica la segunda palabra más frecuente en los datos.

this film was just brilliant casting location scenery story direction everyone's really suited the part they played and you could just imagine being there robert redford's is an amazing actor and now the same being director norman's father came from the same scottish island as myself so i loved the fact there was a real connection with this film the witty remarks throughout the film were great it was just brilliant so much that i bought the film as soon as it was released for retail and would recommend it to everyone to watch and the fly fishing was amazing really cried at the end it was so sad and you know what they say if you cry at a film it must have been good and this definitely was also congratulations to the two little boy's that played the part's of norman and paul they were just brilliant children are often left out of the praising list i think because the stars that play them all grown up are such a big profile for the whole film but these children are amazing and should be praised for what they have done don't you think the whole story was so lovely because it was true and was someone's life after all that was shared with us all

Label: 1

[1, 14, 22, 16, 43, 530, 973, 1622, 1385, 65, 458, 4468, 66, 3941, 4, 173, 36, 256, 5, 25, 100, 43, 838, 112, 50, 670, 22665, 9, 35, 480, 284, 5, 150, 4, 172, 112, 167, 21631, 336, 385, 39, 4, 172, 4536, 1111, 17, 546, 38, 13, 447, 4, 19 2, 50, 16, 6, 147, 2025, 19, 14, 22, 4, 1920, 4613, 469, 4, 22, 71, 87, 12, 16, 43, 530, 38, 76, 15, 13, 1247, 4, 22, 17, 515, 17, 12, 16, 626, 18, 19193, 5, 6 2, 386, 12, 8, 316, 8, 106, 5, 4, 2223, 5244, 16, 480, 66, 3785, 33, 4, 130, 1 2, 16, 38, 619, 5, 25, 124, 51, 36, 135, 48, 25, 1415, 33, 6, 22, 12, 215, 28, 77, 52, 5, 14, 407, 16, 82, 10311, 8, 4, 107, 117, 5952, 15, 256, 4, 31050, 7, 3766, 5, 723, 36, 71, 43, 530, 476, 26, 400, 317, 46, 7, 4, 12118, 1029, 13, 10 4, 88, 4, 381, 15, 297, 98, 32, 2071, 56, 26, 141, 6, 194, 7486, 18, 4, 226, 2 2, 21, 134, 476, 26, 480, 5, 144, 30, 5535, 18, 51, 36, 28, 224, 92, 25, 104, 4, 226, 65, 16, 38, 1334, 88, 12, 16, 283, 5, 16, 4472, 113, 103, 32, 15, 16, 5 345, 19, 178, 32]

-
- Se utilizó la proporción 50/50 para el conjunto de datos de entrenamiento y test.
 - Se utiliza un vocabulario de 5000 palabras
 - Limitaremos las reseñas a 500 palabras, truncando las revisiones más largas y completando con 0 las revisiones más cortas.

Red Feedforward: 500 neuronas de entrada, con una sola capa oculta (250 neuronas) , y una unica salida, batch size=128 ejemplos.

Neural Network	activation	optimizer	epochs	accuracy
Feedforward	relu	adam	5	86.527997
Feedforward	tanh	adam	5	86.308002
Feedforward	relu	adam	5	86.264002
Feedforward	relu	rmsprop	5	84.476000
Feedforward	relu	adam	5	86.420000
Feedforward	relu	adam	15	86.816001
Feedforward	relu	adam	30	86.607999
Feedforward	relu	adam	50	86.556000